TRƯỜNG ĐẠI HỌC SÀI GÒN • KHOA CÔNG NGHỆ THÔNG TIN • CÔNG TRÌNH NGHIÊN CỨU KHOA HỌC HỌC PHẦN MÁY HỌC

KIẾN TRÚC HỌC MÁY XẾP CHỒNG KẾT HỢP KỸ THUẬT KIẾN TẠO ĐẶC TRƯNG VÀ HẬU XỬ LÝ NGOẠI SUY TRONG ĐỊNH GIÁ BẤT ĐỘNG SẢN AMES HOUSING

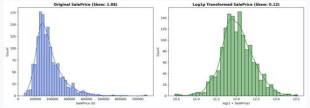
Nhóm tác giả: Ngô Kiều Đình Trung [3124411327] • Nguyễn Đức Tuấn [3124411336] • Dương Hạo Quang [3124411244] • Đặng Ngô Minh Đăng [3124411068] | GVHD: Đỗ Như Tài

THÀNH TÍCH KAGGLE TOÀN CẦU
TOP 126 LEADERBOARD
Public LB RMSLE: 0.11618
5-Fold OOF RMSLE: 0.11171
Độ lệch CV - LB: 0.00447

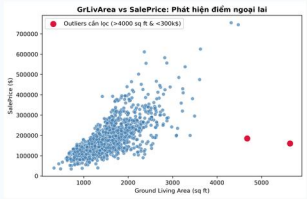
1. TỔNG QUAN BÀI TOÁN & TIỀN XỬ LÝ DỮ LIỆU AMES HOUSING

1.458 Mẫu	1.459 Mẫu	80 -> 261 Chiều	1.88 -> 0.12
Tập Train sau lọc dị biệt	Tập Test đối chứng Kaggle	Không gian đặc trưng mã hóa	Giảm độ lệch Skewness

- **Chuẩn hóa biến mục tiêu SalePrice:** Áp dụng biến đổi logarit tự nhiên cộng một qua hàm log1p giúp giảm mạnh hệ số Skewness từ 1.88 xuống 0.12, đưa phân phối giá nhà về tiệm cận chuẩn Gauss.
- **Bốn nguyên tắc điền khuyết nghiệp vụ:** Gán chuỗi None cho 11 thuộc tính tiện ích không tồn tại như hồ bơi, lối hẻm, hàng rào, lò sưởi, gara, tầng hầm; gán số 0 cho diện tích tiện ích vắng mặt; điền mặt tiền LotFrontage bằng trung vị theo từng tiểu khu Neighborhood; và điền Mode cho các cột thiếu đơn lẻ.
- **Xử lý điểm ngoại lai theo khuyến nghị De Cock [1]:** Phát hiện và loại bỏ 2 căn nhà Id 524 và Id 1299 có diện tích trên 4.000 sq ft nhưng bán dưới 185.000 USD do giao dịch xây dựng dở dang tại khu Edwards.



Hình 1. Phân phối SalePrice trước và sau biến đổi log1p.

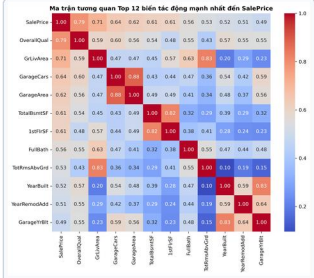


Hình 2. Phát hiện 2 điểm ngoại lai Id 524 và Id 1299.

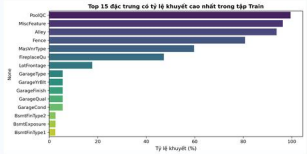
2. KIẾN TẠO SÁU ĐẶC TRƯNG NGHIỆP VỤ & CHUẨN HÓA ĐỘ LỆCH

Nhóm tác giả tổng hợp 6 đặc trưng phái sinh phản ánh trực tiếp giá trị sử dụng thực tế của bất động sản, kết hợp mã hóa thứ bậc thang 0 đến 5 cho 10 thuộc tính chất lượng hoàn thiện và biến đổi hàm log1p cho toàn bộ các đặc trưng định lượng có độ lệch tuyệt đối vượt ngưỡng 0.75:

Đặc trưng mới	Công thức thiết lập	Ý nghĩa nghiệp vụ định giá
TotalSF	**TotalBsmtSF + 1stFlrSF + 2ndFlrSF**	**Tổng diện tích sử dụng toàn bộ căn nhà**
TotalBath	**FullBath + 0.5 Half + BsmtFull + 0.5 BsmtHalf**	**Tổng số phòng tắm quy đổi theo trọng số**
HouseAge	YrSold - YearBuilt	Số năm tuổi công trình tại thời điểm bán
RemodAge	YrSold - YearRemodAdd	Số năm từ lần cải tạo nâng cấp gần nhất
IsRemodeled	1 nếu YearRemodAdd khác YearBuilt, còn lại 0	Chỉ dấu nhị phân nhà đã qua cải tạo
TotalPorchSF	OpenPorch + Enclosed + 3Ssn + ScreenPorch	Tổng diện tích hiên và không gian phụ trợ



Hình 3. Ma trận tương quan 12 biến định lượng hàng đầu.

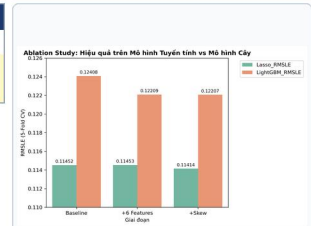


Hình 4. Tỷ lệ khuyết tật của 15 thuộc tính trên tập Train.

3. NGHIÊN CỨU BÓC TÁCH ABLATION STUDY: TUYẾN TÍNH VÀ CÂY

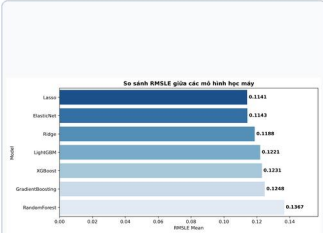
Giai đoạn	Lasso	LightGBM
1. Baseline	0.114519	0.124082
2. +6 Features	**0.114535**	**0.122088**
3. +Skewness	**0.114142**	**0.122067**

- **Đối với LightGBM:** Bổ sung 6 đặc trưng giúp giảm vọt RMSLE từ 0.124082 xuống 0.122088 vì cây quyết định phân hoạch trực giao từng trục nên rất cần biến tổng TotalSF.
- **Đối với Lasso:** Biến đổi độ lệch Skewness ở Giai đoạn 3 giúp giảm sai số về mức tối ưu 0.114142 nhờ đưa phân phối các biến diện tích về dạng đối xứng.



Hình 5. Kết quả thực nghiệm bóc tách 3 giai đoạn.

4. ĐỐI CHUẨN 7 THUẬT TOÁN & LÝ GIẢI TUYẾN TÍNH ÁP ĐẢO CÂY



Hình 6. Đối chuẩn RMSLE 5-Fold CV của 7 mô hình.

- **1. Tỷ lệ chiều trên mẫu cao:** Tập huấn luyện có 1.458 mẫu nhưng mở rộng lên 261 chiều sau mã hóa One-Hot. Trong không gian cao chiều ít mẫu, các nút lá của cây quyết định bị phân mảnh mạnh.
- **2. Cấu trúc liên kết tuyến tính:** Sau biến đổi log1p, mối quan hệ giữa diện tích sàn, chất lượng tổng thể và giá bán mang bản chất đồng biến tuyến tính, phù hợp tự nhiên với siêu phẳng hồi quy.
- **3. Sức mạnh điều chuẩn L1 và L2:** Thuật toán Lasso [6] triệt tiêu các đặc trưng nhiễu về đúng bằng 0, trong khi Ridge kiểm soát đa cộng tuyến giữa các cột diện tích, chống quá khớp vượt trội.

5. KIẾN TRÚC XẾP CHỒNG HAI TẦNG STACKING REGRESSOR OOF

TẦNG CƠ SỞ BASE LEARNERS
Ridge • Lasso • ElasticNet
GradientBoosting • XGBoost • LightGBM

→

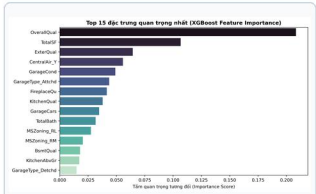
CƠ CHẾ 5-FOLD OUT-OF-FOLD
Sinh ma trận dự đoán ngoài mẫu
Ngăn chặn rò rỉ dữ liệu tuyệt đối

→

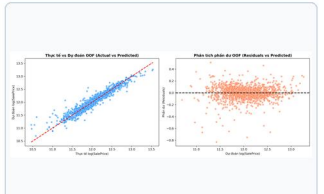
TẦNG TỔNG HỢP META LEARNER
Chuẩn hóa RobustScaler + Lasso
Hệ số điều chuẩn alpha = 0.0005

Hạng	Phương pháp hoặc Mô hình	5-Fold OOF	Đánh giá Hiệu năng Thực nghiệm
1	**Stacking Regressor Hai tầng**	**0.111708**	**Tốt nhất, giảm 0.002358 so với Lasso**
2	Blending Trung bình tổ hợp	0.111823	Kém hơn Stacking thuần túy 0.000115
3	Lasso Tinh chỉnh GridSearchCV	0.114071	Mô hình đơn tốt nhất, R^2 đạt 0.9178
4	ElasticNet Tinh chỉnh	0.114143	Kết hợp L1 và L2 với l1_ratio = 0.9
5	Ridge Tinh chỉnh	0.114243	Mô hình điều chuẩn L2 với alpha = 15
6	LightGBM & XGBoost Tinh chỉnh	0.122138	Đa dạng hóa sai số phi tuyến cho Meta

6. GIẢI THÍCH MÔ HÌNH & PHÂN TÍCH HÌNH THÁI PHẦN DƯ



Hình 7. Top 15 đặc trưng quan trọng nhất trên XGBoost.



Hình 8. Giá trị thực tế với dự đoán OOF và phần dư.

- **Minh chứng giá trị của TotalSF:** Biến OverallQual giữ vị trí số 1, trong khi biến phái sinh TotalSF do nhóm kiến tạo vươn lên vị trí số 2 toàn cục, vượt qua mọi thuộc tính diện tích gốc.
- **Phân tích phần dư & hạn chế:** Hệ số R^2 đạt trên 0.92. Phần dư tập trung đều quanh trục 0 nhưng xuất hiện xu hướng co cụm nhẹ ở hai đầu cực trị dưới 100.000 USD và trên 450.000 USD do lực điều chuẩn.

7. ĐỘT PHÁ HẬU XỬ LÝ: CHẶN TRẦN NGOẠI SUY CĂN NHÀ ID 2550

PHÁT HIỆN NGUY CƠ NGOẠI SUY TRÊN TẬP TEST: Căn nhà Id 2550 có diện tích khổng lồ 5.095 sq ft, giao dịch xây dở dang Partial tại khu dân cư bình dân Edwards bị mô hình ngoại suy tuyến tính đẩy giá vọt lên 824.887,81 USD. Thống kê 98 căn khu Edwards trên tập Train chứng minh giá trung vị chỉ đạt 119.500 USD và mức trần lịch sử chưa từng vượt quá 320.000 USD.

Thống kê khu Edwards	Số mẫu	Nhỏ nhất	Trung vị 50%	Phân vị 75%	Trần lịch sử
SalePrice tập Train	98 căn	58.500 USD	119.500 USD	143.375 USD	320.000 USD

Mã Id	Tiểu khu	Diện tích	Giao dịch	Trước Chặn trần	Sau Chặn trần
Id 2550	**Edwards**	**5.095 sq ft**	**Partial**	**824.887,81 USD**	**320.000,00 USD**
Id 1975	NridgHt	2.470 sq ft	New	555.232,62 USD	555.232,62 USD

8. ĐỐI CHỨNG KAGGLE LEADERBOARD & KẾT LUẬN KHOA HỌC

Phiên bản Đệ trình Kaggle	OOF RMSLE	Public LB	Độ lệch CV-LB	Thứ hạng Kaggle
Stacking + Hậu xử lý Chặn trần	**0.11171**	**0.11618**	**0.00447**	**Top 126 Toàn cầu**
Stacking Thuần túy Chưa xử lý	0.11171	0.12179	0.01008	Tụt hạng do Id 2550



Hình 9. Minh chứng 2 lượt nộp bài đối chứng trên Kaggle.



Hình 10. Minh chứng vị trí Top 126 toàn cầu trên Kaggle.

KẾT LUẬN: Chỉ duy nhất một điểm ngoại suy tại căn nhà Id 2550 đã kéo sai số toàn tập Test từ 0.11618 lên 0.12179. Sự phối hợp chặt chẽ giữa tiền xử lý nghiệp vụ, kiến tạo đặc trưng TotalSF, kiến trúc Stacking OOF hai tầng và hậu xử lý chặn trần ngoại suy đã giúp mô hình đạt độ khái quát hóa vững chắc với độ lệch CV-LB chỉ 0.00447.

Tài liệu tham khảo: [1] D. De Cock, JSE, 2011 • [2] J. H. Friedman, Ann. Stat., 2001 • [3] T. Chen & C. Guestrin, KDD, 2016 • [4] G. Ke et al., NeurIPS, 2017 • [5] D. H. Wolpert, Neural Networks, 1992 • [6] R. Tibshirani, JRSS-B, 1996