PHÂN LOẠI THỂ LOẠI NHẠC TỪ ĐẶC TRƯNG ÂM THANH

Music Genre Classification — LightGBM + XGBoost Ensemble trên dữ liệu bảng

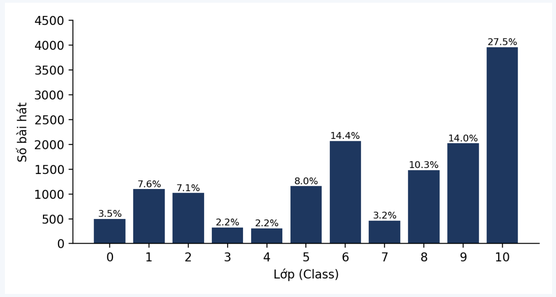
Nhóm 24 – SGU26ML
Challenge 2 · Chương trình Chất lượng cao
Trường Đại học Sài Gòn (SGU)

1 Bài toán & dữ liệu

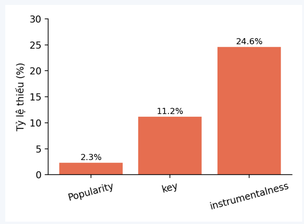
14.396	3.600	14	11
mẫu train	mẫu test	đặc trưng số	lớp (0–10)

Dự đoán **thể loại** của bài hát từ các đặc trưng âm thanh (*danceability*, *energy*, *acousticness*, *loudness*…), độ phổ biến và tên nghệ sĩ/bài hát. Nhãn được ẩn danh (0–10). Cuộc thi: **SHAI – Music Genre Classification** (Kaggle).

2 Khám phá dữ liệu



Mất cân bằng lớp: lớp 10 chiếm 27,5%, lớp 3 & 4 chỉ 2,2%

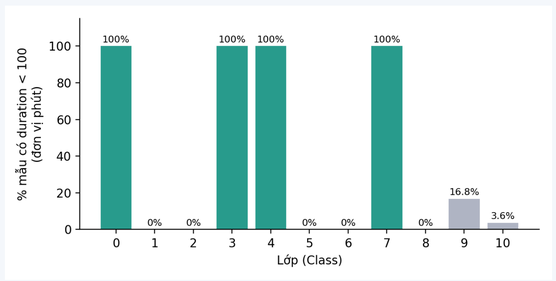


Dữ liệu thiếu

- **instrumentalness** thiếu 24,6%
- **key** thiếu 11,2%
- **Popularity** thiếu 2,3%
- 63,8% bài test có nghệ sĩ đã thấy ở train

! Phát hiện: đơn vị thời lượng

Cột `duration_in min/ms` trộn **phút** (2.075 dòng < 100) và **mili giây**. Tỷ lệ "phút" gần như tất định theo lớp.



% mẫu có duration < 100 theo lớp

3 Phương pháp

Dữ liệu train + test → Feature Engineering → 5-fold Stratified CV

LightGBM, XGBoost → Trung bình xác suất → argmax → nhãn

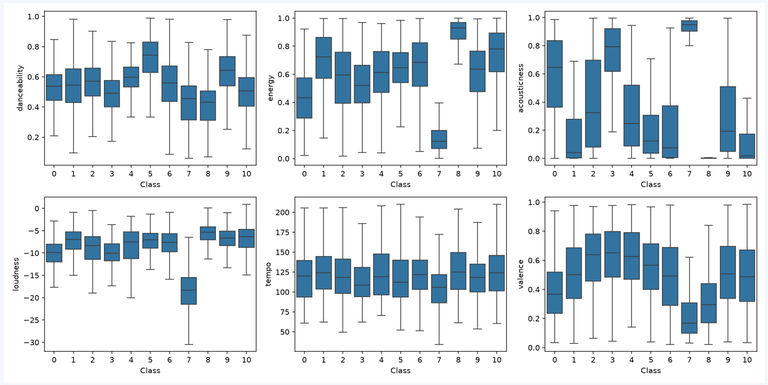
Chuẩn hoá: duration < 100 nhân 60.000 → mili giây. Giữ nguyên giá trị thiếu (cây xử lý trực tiếp).

+10 đặc trưng (14 → 24):

- `dur_was_min` – cờ đơn vị gốc
- `*_na` – cờ thiếu (Popularity, key, instrumentalness)
- `artist_freq`, `track_len`, `track_feat`
- `energy_dance` = energy × danceability
- `loud_energy` = loudness / (energy + 0,001)
- `acoustic_energy` = acousticness − energy

Huấn luyện: lr 0,03 · tối đa 3000 cây · early stopping 100 · subsample 0,8 · colsample 0,7 · LGBM `num_leaves` =31 · XGB `max_depth` =6 · seed 42.

Đặc trưng phân biệt lớp



Lớp 7: acoustic cao, energy thấp · Lớp 8: energy cao, acoustic ≈ 0 · Lớp 5: danceability & speechiness cao

energy tương quan mạnh với **loudness** (r = 0,77) và **acousticness** (r = −0,75). **tempo** gần như không phân biệt được lớp.

4 Kết quả

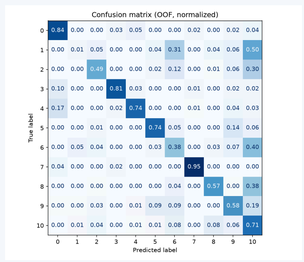
Mô hình	CV Acc	CV Macro-F1
LightGBM, 14 đặc trưng gốc	0,4985	0,4660
LightGBM + FE	0,5731	0,6184
XGBoost + FE	0,5750	0,6166
Ensemble LGBM + XGB	**0,5766**	**0,6208**

0,58055 — Kaggle · Public score

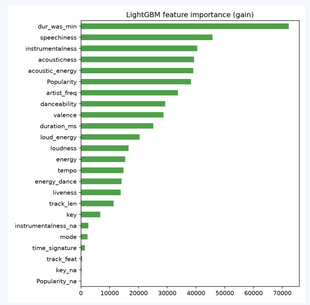
0,56759 — Kaggle · Private score

Feature engineering: **+7,5 điểm accuracy** và **+15,2 điểm Macro-F1** so với mô hình nền.

5 Phân tích sai số



Ma trận nhầm lẫn OOF



Độ quan trọng (gain)

- Tốt: lớp **7** (recall 0,95), **0** (0,84), **3** (0,81)
- Kém: lớp **1** (0,01) và lớp **6** (0,38), phần lớn bị nhầm sang lớp 10
- Test: lớp 10 bị dự đoán 38,9% (train: 27,5%)

6 Hạn chế & kết luận

Lưu ý: `dur_was_min` là đặc trưng quan trọng nhất nhưng nhiều khả năng phản ánh cách thu thập dữ liệu, không phải âm nhạc.

- Chưa xử lý mất cân bằng lớp; chưa tinh chỉnh siêu tham số / ablation
- Early stopping trên fold kiểm định → CV hơi lạc quan
- Hướng tiếp: class weight, target encoding nghệ sĩ, stacking, nhiều seed

Kết luận: FE + ensemble nâng Macro-F1 CV từ 0,466 lên 0,621; mô hình nhận diện tốt lớp có đặc trưng đặc thù nhưng thiên về lớp đa số.

Tài liệu tham khảo: [1] Ke et al., LightGBM, NeurIPS 2017 · [2] Chen & Guestrin, XGBoost, KDD 2016 · [3] Friedman, Gradient Boosting Machine, Ann. Stat. 2001 · [4] Kohavi, Cross-validation, IJCAI 1995 · [5] Tzanetakis & Cook, Musical genre classification, IEEE TSAP 2002

Dữ liệu & cuộc thi: kaggle.com/competitions/shai-music-genre-classification