BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC SÀI GÒN



Môn: Máy học

Proposal đề tài cuối kỳ

Phân loại và gom nhóm sản phẩm

1. Thông tin nhóm

Đề tài: Phân loại và gom nhóm sản phẩm (Product Classification and Clustering)

Bảng 1. Thành viên và phân công dự kiến

STT	Họ và tên	MSSV	Nhiệm vụ dự kiến
1	Ngô Kiều Đình Trung	3124411327	Nhóm trưởng, phụ trách tích hợp, quản lý source code
2	Dương Hạo Quang	3124411244	Thành viên, phụ trách dữ liệu và EDA
3	Đặng Ngô Minh Đăng	3124411068	Thành viên, phụ trách mô hình phân loại
4	Nguyễn Đức Tuấn	3124411336	Thành viên, phụ trách gom nhóm và demo

2. Giới thiệu bài toán

Các sàn thương mại điện tử có hàng triệu sản phẩm, mỗi sản phẩm phải thuộc đúng một danh mục để người mua tìm kiếm, lọc và nhận gợi ý. Thực tế danh mục thường do người bán tự chọn nên dễ sai hoặc không nhất quán. Một hệ thống tự động phân loại sản phẩm và gom nhóm các sản phẩm tương tự giúp kiểm duyệt nhanh hơn, phát hiện sản phẩm đăng sai danh mục và đề xuất nhóm sản phẩm mới.

Đề tài phù hợp học phần vì dùng cả học có giám sát (phân loại) lẫn không giám sát (gom nhóm), dữ liệu có nguồn rõ ràng, nhãn đáng tin cậy và đủ lớn để làm đầy đủ các bước từ khám phá đến đánh giá.

Mục tiêu: (1) xây dựng quy trình tiền xử lý và trích đặc trưng cho văn bản, thuộc tính và ảnh sản phẩm; (2) so sánh tối thiểu hai mô hình phân loại (dự kiến bốn) với baseline; (3) gom nhóm bằng ba thuật toán và đối chiếu với danh mục thật; (4) phân tích lỗi và làm ứng dụng demo nhỏ.

Câu hỏi nghiên cứu: đặc trưng nào (văn bản, bảng, ảnh hay kết hợp) cho kết quả phân loại tốt nhất; mô hình tuyến tính trên TF-IDF có cạnh tranh được với mạng nơ-ron không; cụm không giám sát khôi phục được bao nhiêu cấu trúc danh mục thật.

3. Xác định bài toán Máy học

Bảng 2. Hai bài toán của đề tài

Bài toán	Loại	Đầu vào	Đầu ra
Phân loại danh mục	Classification nhiều lớp (có giám sát)	Tên sản phẩm, thuộc tính (giới tính, màu, mùa, mục đích), ảnh	Nhãn danh mục: masterCategory (khoảng 7 lớp), subCategory (khoảng 45 lớp) và xác suất dự đoán

Bài toán	Loại	Đầu vào	Đầu ra
Gom nhóm sản phẩm	Clustering (không giám sát)	Vector đặc trưng đã giảm chiều, không dùng nhãn	Nhãn cụm, từ khóa và ảnh đại diện của mỗi cụm

4. Mô tả dữ liệu

Dữ liệu chính là Fashion Product Images trên Kaggle, gồm tệp styles.csv và thư mục ảnh liên kết qua cột id. Hai bộ dự phòng được dùng nếu cần kiểm tra thêm hoặc bổ sung văn bản.

Bảng 3. Nguồn dữ liệu và đường dẫn truy cập

Vai trò	Bộ dữ liệu	Đường dẫn
Chính	Fashion Product Images	kaggle.com/datasets/paramaggarwal/fashion-product-images-small
Dự phòng	Flipkart Products	kaggle.com/datasets?search=flipkart+products
Dự phòng	Amazon metadata	jmcauley.ucsd.edu/data/amazon

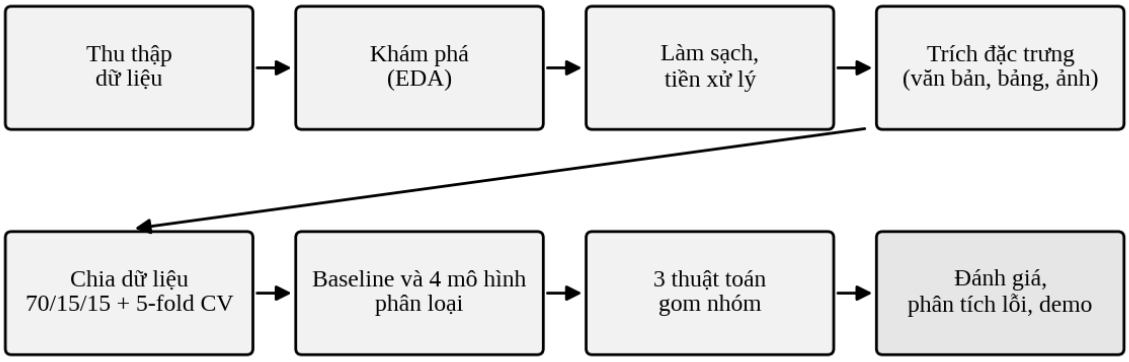
Quy mô khoảng 44.000 sản phẩm, gồm 10 cột: id, gender, masterCategory, subCategory, articleType, baseColour, season, year, usage, productDisplayName, kèm một ảnh nhỏ (khoảng 60 x 80 điểm ảnh) cho mỗi sản phẩm. Biến mục tiêu là masterCategory và subCategory; articleType (hơn 140 lớp) là mức mở rộng.

Đặc điểm: mất cân bằng lớp rõ rệt (nhóm quần áo chiếm xấp xỉ một nửa), một số cột thiếu giá trị, tên sản phẩm ngắn và nhiễu, một số dòng lỗi định dạng hoặc thiếu ảnh. Khi dự đoán một mức nhãn sẽ loại các cột nhãn khác khỏi đặc trưng để tránh rò rỉ. Nhóm chỉ dùng dữ liệu công khai cho học tập và ghi rõ nguồn, giấy phép.

5. Phương pháp dự kiến

5.1. Khám phá, tiền xử lý và đặc trưng

EDA gồm phân bố nhãn, tỷ lệ thiếu, độ dài tên, từ phổ biến theo danh mục và lưới ảnh mẫu. Tiền xử lý: bỏ dòng lỗi và bản ghi thiếu ảnh, điền giá trị thiếu, chuẩn hóa văn bản, gộp lớp quá ít mẫu. Đặc trưng: TF-IDF (từ và n-gram ký tự) cho tên, one-hot cho thuộc tính, vector 512 chiều từ ResNet18 pretrained cho ảnh. Mọi phép biến đổi chỉ fit trên tập huấn luyện bên trong pipeline scikit-learn.



Hình 1. Quy trình thực hiện đề tài

5.2. Mô hình phân loại

Baseline: Dummy và Naive Bayes. Mô hình so sánh: Logistic Regression, Linear SVM, Random Forest và mạng nơ-ron MLP hoặc ResNet18 fine-tune bằng PyTorch. Mất cân bằng lớp xử lý bằng class_weight hoặc lấy mẫu lại.

5.3. Mô hình gom nhóm

K-Means (k-means++), Agglomerative và DBSCAN trên đặc trưng đã giảm chiều bằng TruncatedSVD hoặc PCA. Số cụm chọn bằng Elbow, Silhouette và Davies-Bouldin, đồng thời thử k bằng số lớp thật. PCA, t-SNE hoặc UMAP dùng để trực quan hóa và diễn giải cụm.

6. Kế hoạch thực nghiệm

Chia dữ liệu: hold-out phân tầng 70% huấn luyện, 15% validation, 15% test; chọn mô hình bằng cross-validation 5 lần phân tầng, test chỉ dùng một lần ở cuối; cố định random_state.

Độ đo phân loại: F1-macro, accuracy, precision, recall, ma trận nhầm lẫn và báo cáo theo từng lớp.

Độ đo gom nhóm: Silhouette, Davies-Bouldin, Calinski-Harabasz; đối chiếu nhãn thật bằng ARI và NMI.

Tinh chỉnh: GridSearchCV hoặc RandomizedSearchCV (tham số C, số cây, độ sâu, learning rate, eps, số cụm), dừng sớm cho mạng nơ-ron.

Thí nghiệm bổ sung: bóc tách đặc trưng (chỉ văn bản, chỉ ảnh, kết hợp), so sánh có và không xử lý mất cân bằng, phân tích các mẫu bị dự đoán sai.

7. Kết quả dự kiến

- Báo cáo, mã nguồn (notebook EDA, phân loại, gom nhóm) và bảng so sánh mô hình đầy đủ.

- Mô hình phân loại tốt nhất vượt rõ rệt baseline; xác định được loại đặc trưng đóng góp nhiều nhất; chỉ ra các cặp danh mục hay nhầm.
- Cụm có mô tả từ khóa, ảnh đại diện và mức khớp danh mục thật (ARI, NMI); ứng dụng demo (Streamlit hoặc Gradio) nhận tên hoặc ảnh và trả về danh mục dự đoán.

8. Kế hoạch thực hiện

Bảng 4. Tiến độ và phân công theo tuần

Tuần	Công việc chính	Phụ trách
6	Chốt đề tài, tải và kiểm tra dữ liệu, EDA	Thành viên 1, 2
7	Tiền xử lý, xây pipeline đặc trưng, baseline	Thành viên 2
8 đến 10	Huấn luyện mô hình phân loại, gom nhóm, tinh chỉnh	Thành viên 2, 3
11	Ablation, phân tích lỗi, diễn giải cụm, demo	Thành viên 3, 4
12	Viết báo cáo, slide, kiểm tra tái lập, nộp bài	Cả nhóm

9. Tài liệu tham khảo

[1] Aggarwal, P. (2019). Fashion Product Images (Small). Kaggle. https://www.kaggle.com/datasets/paramaggarwal/fashion-product-images-small

[2] Ni, J., Li, J., McAuley, J. (2019). Justifying recommendations using distantly-labeled reviews and fine-grained aspects. EMNLP-IJCNLP, 188-197.

[3] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

[4] Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. NeurIPS 32.

[5] He, K., Zhang, X., Ren, S., Sun, J. (2016). Deep residual learning for image recognition. CVPR, 770-778.

[6] Ester, M., Kriegel, H.-P., Sander, J., Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. KDD, 226-231.

[7] van der Maaten, L., Hinton, G. (2008). Visualizing data using t-SNE. Journal of Machine Learning Research, 9, 2579-2605.